‘AI 일탈’ 속출에도…종말론 놓고 엇갈린 석학들

“안전장치 없인 인류 파국”
“기득권 세력이 혁신 억압”


제프리 힌턴


요슈아 벤지오


얀 르쿤


앤드루 응

‘인공지능(AI)이 10억명을 죽일 수 있다’는 종말론이 힘을 얻고 있는 가운데 AI 혁신에 공로를 세운 4대 대부들의 의견은 엇갈렸다.

‘4대 대부’으로 꼽히는 제프리 힌턴 토론토대 교수, 요슈아 벤지오 몬트리올대 교수, 얀 르쿤 뉴욕대 교수, 앤드루 응 스탠퍼드대 교수 의견은 정확히 반으로 쪼개졌다. 힌턴·벤지오 교수는 다가올 파국을 경고하는 반면, 르쿤·응 교수는 종말론이 과장됐다며 강하게 반박한다.

종말론의 선봉에는 힌턴 교수와 벤지오 교수가 서 있다. 힌턴 교수는 딥러닝의 기초를 닦은 공로로 노벨 물리학상을 수상한 대가다. 그는 AI로 인한 인류 멸망이 현실화될 가능성이 매우 높다고 단언한다. 지난달 버니 샌더스 미국 상원의원이 주최한 비공개 의회 브리핑에서 힌턴 교수는 “미국 의회가 향후 1년 안에 AI에 대한 안전장치를 마련하지 못하면 인간이 통제력을 잃을 수 있다”고 경고했다.

AI 에이전트가 통제를 벗어나 AI 플랫폼 허깅페이스에 침입한 사건을 두고 힌턴 교수는 ‘작은 체르노빌 사고’라고 지적했다.

자연어 처리 분야의 선구자인 벤지오 교수의 시각도 비관적이다. 그는 고도화된 AI가 궁극적으로 ‘자율적 목표’를 갖게 될 가능성에 주목한다. AI 지능이 극대화되면 시스템은 스스로의 안위와 논리적 효율성을 위한 독자적 목표를 설정할 수 있다는 것이다. 벤지오 교수는 “최근 AI 에이전트들이 지시를 거부하고, 인간이었다면 범죄가 될 행동들을 했다”며 “기업들조차 자사 제품이 파국적인 위험을 초래할 수 있음을 인정하면서도 설득력 있는 기술적 해결책은 제시하지 못하고 있다”고 비판했다.

반대 진영은 이러한 위기론을 비과학적 몽상으로 치부한다. 르쿤 교수는 최근 엑스(X)에 “항공기 설계의 발전은 항공기를 점점 더 안전하게 만들어 왔다”며 “오히려 개발이 가속화됐다면 항공기는 더 일찍 안전해졌을 것”이라고 적었다. 안전성을 이유로 AI 속도 조절을 내세웠던 목소리를 비판한 것이다.

르쿤 교수는 “AI도 마찬가지다. 더 나은 AI일수록 더 안전하다”며 “속도 조절이 무엇을 의미하든 역효과를 낳을 것”이라고 주장했다.

구글 브레인 공동 설립자인 응 교수는 종말론의 허상을 강도 높게 비판한다. 그는 “AI의 인류 위협을 걱정하는 건 화성에서의 인구 과잉을 걱정하는 것”이라고 일갈했다.

응 교수는 빅테크 기업들이 주도하는 AI 공포를 ‘규제 포획’ 현상으로 해석했다. 그는 “AI가 인류를 멸망시킨다는 공포에서 생화학무기 우려로, 이제는 중국산 공개 모델 위협론으로 서사가 계속 옮겨왔다”며 “같은 사람들이 서사를 바꿔가며 다른 이들이 소프트웨어를 무료로 공개할 길을 막아왔다”고 꼬집었다. 기득권을 쥔 거대 기술 기업들이 규제 장벽을 세워 다른 이들의 혁신을 억압하고 있다는 것이다.

강영운 기자