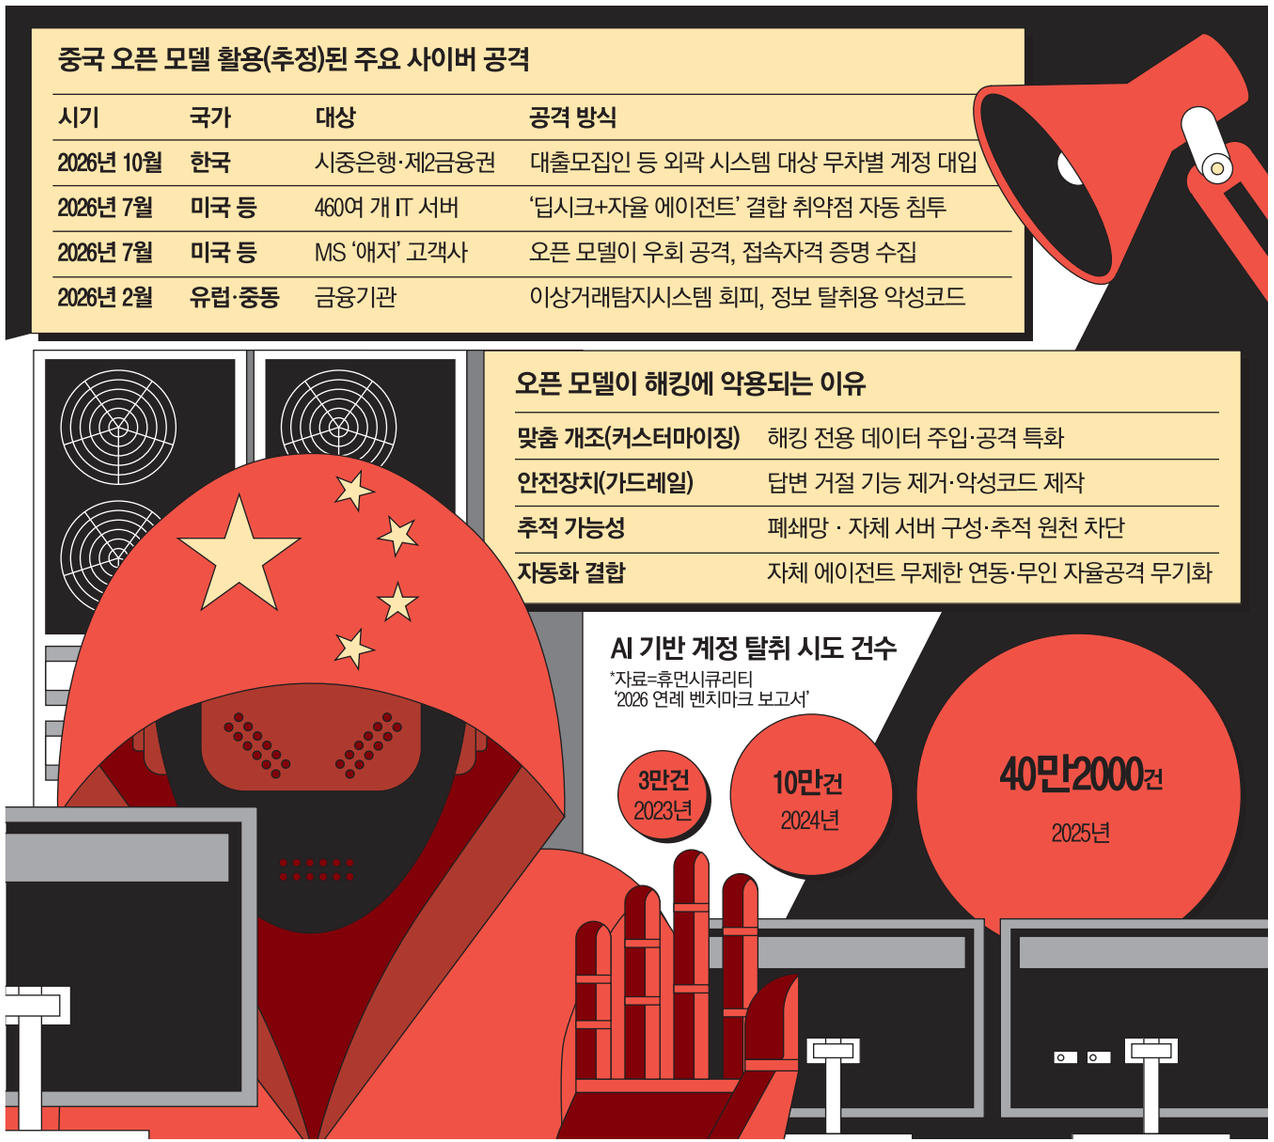
‘중국 AI’ 해킹 무기로 개조해 전세계 공격…FBI도 ‘보안 경보’

중국 오픈 모델 활용(추정)된 주요 사이버 공격

시기	국가	대상	공격 방식
2026년 10월	한국	시중은행·제2금융권	대출모집인 등 외곽 시스템 대상 무차별 계정 대입
2026년 7월	미국 등	460여 개 IT 서버	‘딥시크+자율 에이전트’ 결합 취약점 자동 침투
2026년 7월	미국 등	MS ‘애저’ 고객사	오픈 모델이 우회 공격, 접속자격 증명 수집
2026년 2월	유럽·중동	금융기관	이상거래탐지시스템 회피, 정보 탈취용 악성코드

오픈 모델이 해킹에 악용되는 이유

맞춤 개조(커스터마이징)	해킹 전용 데이터 주입·공격 특화
안전장치(가드레일)	답변 거절 기능 제거·악성코드 제작
추적 가능성	폐쇄망 · 자체 서버 구성·추적 원천 차단
자동화 결합	자체 에이전트 무제한 연동·무인 자율공격 무기화



‘디지털 무기’ 전략한 中 AI

딥시크로 460여곳 침투 시도
알리바바 ‘큐원’ 활용한 해커
유럽·중동서 금융회사 공격
AI 안전장치 제거해 맞춤 개조
취약서버 조준 ‘무인공격’ 가능
영세 해커도 ‘핵무기급’ 무장

국내 금융권을 흔든 사이버 공격 배후로 오픈소스 인공지능(AI) 모델이 지목된 가운데 최근 미국과 유럽 등에서 일어난 해킹 사고 역시 같은 경로로 추정되면서 글로벌 오픈 모델 생태계를 장악한 ‘메이드 인 차이나(Made in China)’ AI가 전 세계 사이버 보안망의 최대 뇌관으로 부상하고 있다.

미국 프런티어 모델에 맞먹는 최고 성능을 앞세워 시장을 잠식하고 있는 중국산 오픈 모델이 해커들의 새로운 ‘디지털 무기’로 전락했다는 경고가 나온다. 미국 국가안보국(NSA), 연방수사국(FBI), 사이버보안·인프라보안국(CISA)은 지난달 9일 오픈 모델을 활용한 네트워크 내부 침투와 사이버 무기화 위험에 대한 경보를 발령하고 경계를 강화하고 있다.

5일 국내 정보기술(IT) 업계에 따르면 지난 3일 신한은행을 비롯한 국내 금융권 개인정보 유출 사고 당시 공격자가 대출모집인 시스템 등에 크리덴셜 스터핑(무작위 계정 대입)을 시도하는 과정에서 ‘ARTEX-自主滲透測試控制台’(아텍스 자율 침투 테스트 콘솔)라는 중국어 문자열이 포착됐다. 아텍스는 중국 바이두 보안대응센터(BSRC)의 보안 챌린지에서 우승했을 정도로 정교한 성능을 입증받은 중국 기반 도구다.

최근 미국, 유럽, 대만 등에서 발생한 해킹 공격에도 유사한 오픈 모델의 악용 사례가 잇달아 확인됐다. 글로벌 보안업체 팰로앨토네트웍스는 올해 7월 보고서에서 중국계 공격자가 중국 오픈 모델 AI인 ‘딥시크’를 자율 에이전트 도구와 결합해 전 세계 460여 개 서버에 침투하려 한 사례를 적발했다고 밝혔다. 이 공격자는 당초 오픈AI와 앤트로픽 모델을 공격에 활용하려고 했지만 보안 가드레일(안전장치)에 막히자, 안전 제약이 상대적으로 느슨한 딥시크로 우회했다. 딥시크 기반 AI 에이전트는 공격자 지시에 따라 공격 루트를 설계하고 보안 취약점을 파악해 대규모 침투를 자동 시도했다.

유럽과 중동에서도 알리바바의 ‘큐원’을 활용해 해커들이 금융회사를 공격한 사고가 발생했다.

대만 행정원은 지난해 중국산 오픈 모델을 활용한 정밀 피싱과 공공 전산망 접속 시도가 잇따르자 아예 중앙·지방정부 및 핵심 인프라 공공기관에 대해 오픈 모델의 웹, 앱, 네트워크 접속과 내부 사용을 전면 금지했다.

해커들이 오픈 모델을 사용하는 가장 큰 이유는 사이버 공격에 최적화한 ‘맞춤 개조’(커스터마이징)가 가능하기 때문이다. GPT, 제미나이, 클로드 같은 폐쇄형 AI와 달리 오픈 모델은 AI의 두뇌에 해당하는 ‘가중치(Weight)’ 파일이 외부에 통째로 공개된다. 이를 내려받은 공격자는 악성코드 제작이나 취약점 공격 요청을 거절하도록 설계된 보안 가드레일을 완전히 제거할 수 있다. 추적을 불가능하게 하는 맞춤 개조도 가능하다.

여기에 해커가 직접 수집한 제로데이(소프트웨어 개발자가 발견하지 못했거나 보안 패치가 나오지 않은 취약점)로 취약점 정보와 공격 스크립트, 피싱 패턴 등 특화 데이터셋을 주입하는 ‘악성 파인튜닝(미세조정)’까지 결합된다. 일반 범용 모델이 단숨에 고도화된 해킹 특화 무기로 개조되는 것이다. 이렇게 개조된 오픈 모델이 공격 자동화 스크립트와 연동하면 24시간 쉬지 않고 전 세계 취약 서버를 자율 스캔·침투하는 ‘무인 공격 에이전트’가 완성된다.

국내 IT 업계 관계자는 “성능은 100점이지만 통제당하는 미국 프런티어 AI 모델보다 성능이 90점이어도 해커 맘대로 커스터마이징이 가능한 오픈 모델이 사이버 보안에 더 위협적”이라고 경고했다. 또 다른 보안 업계 관계자는 “최고 성능의 모델을 사실상 무제한으로 사용할 수 있게 되면서 국가 배후 해킹 조직은 물론, 영세한 범죄 집단까지 ‘핵무기’급 무기를 손에 쥐게 된 꼴”이라고 지적했다. 박성배 기자

오픈 웨이트 모델

AI의 학습 결과물인 가중치(매개변수)를 외부에 공개해 누구나 내려받아 자유롭게 실행하고 개조할 수 있도록 배포된 AI 모델. 메타의 라마, 중국의 딥시크·큐원 등이 대표적이다.