명령어 몇 줄로 'AI 해킹 툴' 뚝딱… 무기박람회 온듯 종류도 다양

AI 공격 도구 만들어보니

9일 개발자 커뮤니티 깃허브에서 확인한 인공지능(AI) 해킹 관련 툴은 단순히 하나의 종류로 분류하기 어려웠다. AI가 침투 경로를 직접 탐색하는 자율형 에이전트부터 여러 해킹 도구를 통합 관리하는 플랫폼, 공격자의 판단을 지원하는 AI 보조 프로그램까지 다양한 형태로 세분화돼 있었다.

◆ 클릭 한번에 깔리는 '해킹 툴'

가장 먼저 눈에 띈 미국의 '스트릭스(Strix)'는 표적을 집요하게 파고드는 정밀 타격에 특화된 도구였다. 아르텍스가 대상을 넓게 훑으며 침투 경로를 샅샅이 뒤지는 그물형 정찰기라면 스트릭스는 취약점으로 의심되는 틈새를 포착하고 끝까지 미사일을 퍼부어 뚫어내는 전투기 같았다.

아랍에미리트(UAE)의 '펜타지(PentAGI)'는 다중 에이전트 협업 구조를 전면에 내세웠다. 하나의 AI가 모든 작업을 수행하는 대신 정찰·취약점 분석·공격 경로 설계를 각기 다른 AI 에이전트가 나눠 맡는 일종의 '디지털 작전참모 본부' 형태였다. 검증된 해킹 툴들이 이들의 손발처럼 연결돼 있어 목표를 지정하는 순간 자율적으로 역할을 분담해 타격 계획을 세우도록 짜여 있었다.

미국의 '섀넌(Shannon)'은 아예 접근 방식이 달랐다. 무작정 닫힌 문을 두드려보는 대신 시스템을 구축할 때 짠 '설계도(소스코드)' 자체를 정밀 분석하는 데 강점이 있었다. 아르텍스가 완성된 외부 웹사이트의 겉면을 두드려보는 '외부 침투형'이라면 섀넌은 내부 코드를 한 줄 한 줄 해부해 인간 개발자도 놓친 논리적 맹점을 집어내는 '코드 해부형'이었다.

이 밖에도 싱가포르 난양공대의 펜테스트GPT, 중국의 사이버스트라이크AI, CAI, 해킹버디GPT 등 전 세계 산학연 주도로 개발된 정교한 도구들이 클릭 한번으로 설치가 가능했다.

더욱 심각한 문제는 이들 도구의 압도적인 진화 속도다. 개발진은 새로운 취약점을 메우거나 추가하는 수준을 넘어 최신 AI 언어모델을 접목해 에이전트의 자체 판단력과 자율수행 능력을 빠르게 끌어올리고 있다.

◆ 한 달 새 10여 차례 '실시간 진화'

최근 한 달 사이에만 무려 10차례가 넘는 코드 수정과 버전 패치를 단행했다. 한국 금융권 해킹으로 떠들썩해진 후인 지난 8일 새벽에도 새로운 업데이트가 이뤄졌다.

업데이트 내역은 단순한 오탈자 수정이나 사소한 오류 개선 수준이 아니었다. 중국의 딥시크나 즈푸AI(Zhipu AI)의 GLM 등 최신 거대언어모델(LLM)과의 연동성을 대폭 높이고 공격 대상 웹사이트의 접속 상태(세션)를 끈질기게 유지하며 보안 추적을 따돌리는 우회 통로(프록시) 기능을 극도로 정교화하는 내용이었다. 한마디로 '실제 침투 성공률'을 극대화하는 방향으로 코드가 쉴 새 없이 벼려지고 있었다.

전통적인 사이버 보안의 문법에서는 새로운 악성코드 변종이 출현하고 이를 방어막이 학습해 막아내는 데 통상 수주에서 수개월이 걸렸다. 보안 기업들은 알려진 악성코드의 고유한 지문(시그니처)을 분석해 백신을 만들었다. 하지만 지금은 방어자가 무기의 성격을 파악하기도 전에 공격 도구가 새로운 AI 모델의 지능을 흡수하며 실시간으로 진화하고 있다. 인간이 백신을 만드는 속도가 변이를 따라잡기 불가능한 수준이다.

특히 아르텍스는 외부 LLM을 연결해 사용하는 구조다. 해킹 툴 자체를 업그레이드하지 않더라도 외부 AI 모델의 성능이 높아지면 더 복잡한 작업을 수행할 잠재력이 생긴다.

보안기업 스틸리언의 박찬암 대표는 "빛의 속도로 진화하고 공격하는 AI를 막을 무기는 'AI'뿐"이라며 사람처럼 위장한 로봇을 실시간으로 감지하고 자율적으로 방어 패치를 적용하는 '능동형 AI 보안체계'로 즉각 전환할 것을 조언했다. 실제로 AI 방어체계가 사람보다 빠르게 작동한 사례도 나왔다. 지난달 국가정보원과 북대서양조약기구(NATO) 사이버방위센터 등이 주관한 국제 사이버훈련 'APEX 2026'에서는 스틸리언이 국방부 사이버작전사령부·금융보안원 등과 꾸린 자율형 AI 방어팀이 23개국 참가팀 중 1위를 차지했다. 이 AI는 사람 개입 없이 개별 침해 케이스를 평균 10.5분 만에 처리했고 공격이 시작되기 전 예정된 침투 시나리오의 65%에 해당하는 취약점을 미리 패치했다. 다만 도구가 공개돼 있다는 사실 자체가 역설적으로 방어의 출발점이 될 수 있다는 지적도 나온다. 공격 도구의 소스코드와 업데이트 내역이 깃허브에 실시간으로 올라오는 만큼 방어 측도 같은 속도로 이를 분석해 탐지 규칙에 반영할 수 있기 때문이다. 오찬종 기자



아르텍스는 자율 침투·공격형 정밀 타격형·코드 분석형부터 다중 AI 협업까지 유형 세분화

AI모델 연동, 실시간으로 변이 기존 보안 문법으론 대응 못해 능동형 AI 방어체계 전환 시급